



ZENASSIST - AI BENCHMARK

Classification Automatique des Réclamations Clients

Étude comparative : Large Language Model (LLM) vs Machine Learning Traditionnel

Olivier BARTHE - Août 2026 - Projet 12

Contexte & Problématique Métier chez ZenAssist



CONSTAT ACTUEL

- 200 réclamations/jour par client en moyenne.
- Tri et routage 100% manuels par l'équipe support.
- Goulot d'étranglement ralentissant la résolution.
- Impact négatif sur la satisfaction client.



OBJECTIF PROJET

- Automatiser l'étiquetage par catégorie produit.
- Router immédiatement le ticket au bon service.
- Garantir un temps de réponse en < 1 seconde.
- Déploiement pilote auprès de 5 clients (~1 000 tickets/j).



CONTRAINTES INTERNES

- Équipe technique restreinte : 1 PO, 1 Dev Front, 1 Dev Back.
- Aucun expert Data Science / IA en interne.
- Nécessité d'une solution simple à maintenir.
- Maîtrise stricte du coût d'infrastructure et d'exploitation.

Analyse Exploratoire des Données (EDA)

Résultats du prétraitement et de la structuration des réclamations :

- **Volume de Données :**

1 282 355 réclamations brutes analysées. 383 564 comportent une description textuelle complète (29,9%). 16 441 doublons supprimés pour un total unique de 367 123 réclamations.

- **Harmonisation de la Taxonomie :**

Regroupement des catégories historiques (doublons de dénominations) en 10 catégories de produits claires et équilibrées.

- **Distribution des Classes :**

Credit reporting (30.0%), Debt collection (23.0%), Mortgage (14.4%), Credit card (11.3%), Bank account (7.5%), Student loan (5.9%), Payday loan (4.2%), Money transfer (1.9%), Vehicle loan (1.6%).

- **Longueur des Réclamations :**

Moyenne : 201.8 mots (~270 tokens). Médiane : 141 mots. 95% des réclamations font moins de 600 mots. Format idéal pour l'inférence.

Cadre d'Évaluation & Métriques Clés

MÉTRIQUES DE PERFORMANCE IA

- **Accuracy globale**

Pourcentage total de réclamations correctement orientées.

- **F1-Score (Weighted / Macro)**

Équilibre entre Précision et Rappel, pondéré par l'effectif des catégories pour tenir compte du déséquilibre des classes.

- **Précision & Rappel par classe**

Évaluation fine sur chaque type de produit (évitement des faux positifs/négatifs).

- **Matrice de confusion**

Visualisation des erreurs de routage entre catégories proches.

MÉTRIQUES SYSTÈME & PRODUCTIVITÉ

- **Latence d'inférence (ms / ticket)**

Temps nécessaire au traitement d'un ticket pour garantir une expérience utilisateur fluide en direct.

- **Coût d'Inférence / Exploitation**

Coût récurrent lié aux appels API ou à l'hébergement serveur (en €/mois).

- **Complexité d'Implémentation**

Charge de travail initiale requise pour la mise en production par l'équipe Web.

- **Maintenance & Évolutivité**

Facilité d'ajout de nouvelles catégories sans réingénierie complexe.

Résultats : Approche LLM (Google Gemini 3.5 Flash Lite)

Évaluation avec Prompting Structuré sur 1 000 réclamations de test :

- **Accuracy globale :**

81.00 % (810 réclamations bien classées sur 1 000)

- **Weighted F1-Score :**

0.81

- **Temps de réponse moyen (Latence) :**

0.458 seconde par ticket (458 ms)

- **Points Forts par Catégorie :**

Mortgage (F1: 0.93), Student Loan (F1: 0.86), Credit Reporting (F1: 0.83), Credit Card (F1: 0.83), Debt Collection (F1: 0.82)

- **Limites constatées :**

Confusion sur les catégories minoritaires complexes (Payday loans F1: 0.25 souvent confondu avec Debt collection).

Résultats : Approche Machine Learning Traditionnel

Entraînement de 3 modèles sur 293 698 exemples :

- **Modèle Gagnant : Régression Logistique :**

Accuracy : 85.70% sur l'échantillon 1k | Accuracy : 84.72% sur le test complet (73 425 tickets). F1-Weighted : 0.8548.

- **Autre Modèle : Multinomial Naive Bayes :**

Accuracy : 82.20% (1k) / 81.54% (73k). Temps d'entraînement ultra-rapide (0.49 s). F1-Weighted : 0.8196.

- **Autre Modèle : Linear SVM (SGD) :**

Accuracy : 79.60% (1k) / 80.16% (73k). F1-Weighted : 0.7800.

- **Vitesse d'Inférence Exceptionnelle :**

Latence moyenne de 0.002 ms par ticket (2 microsecondes) avec la Régression Logistique.

Tableau Comparatif Synthétique (Iso-Périmètre 1 000 Tickets)

Critère de Comparaison	LLM (Gemini 3.5 Flash Lite)	Machine Learning (Logistic Reg)	Gagnant
Accuracy Globale (1k sample)	81.00 %	85.70 %	🏆 ML (+4.7%)
F1-Score (Weighted)	0.81	0.85	🏆 ML (+0.04)
Latence d'inférence (par ticket)	458 ms (0.458 s)	0.002 ms (0.000002 s)	🏆 ML (x200 000 plus rapide)
Coût d'Exploitation (pour 1M tickets)	~500 € (Facturation API)	0.00 € (Inclus CPU local)	🏆 ML (Facture nulle)
Compétence IA requise en interne	Aucune (API REST simple)	Moyenne (Scikit-Learn Python)	🏆 LLM
Flexibilité / Évolution des catégories	Élevée (Mise à jour du prompt)	Nécessite un ré-entraînement	🏆 LLM

Analyse des Avantages et Inconvénients



APPROCHE LLM (Gemini 3.5 Flash Lite)



AVANTAGES :

- + Mise en place immédiate sans entraînement de modèle.
- + S'adapte facilement à de nouvelles consignes via prompt.
- + Excellente compréhension du langage naturel.

✗ INCONVÉNIENTS :

- Coût récurrent d'API s'accroissant avec le volume.
- Latence élevée (458 ms/ticket).
- Dépendance envers un fournisseur tiers.



APPROCHE MACHINE LEARNING (Régression Logistique)



AVANTAGES :

- + Meilleure précision globale (85.70% vs 81.00%).
- + Vitesse d'exécution ultra-rapide (0.002 ms).
- + Coût d'exploitation NUL (tourne sur CPU local).
- + Indépendance totale et souveraineté des données.

✗ INCONVÉNIENTS :

- Nécessite un ré-entraînement lors du changement de catégories.
- Nécessite un script Python de vectorisation et prédiction.

Recommandation Finale & Justification



RECOMMANDATION OFFICIELLE : ADOPTER L'APPROCHE MACHINE LEARNING (TF-IDF + REGRESSION LOGISTIQUE)

1. Précision Maximale (+4.7%)

Le modèle Machine Learning atteint 85.70% d'accuracy contre 81.00% pour Gemini 3.5 Flash Lite sur le même jeu de test.

2. Temps de Réponse quasi Instantané

Avec 0.002 ms par ticket, la classification s'effectue en temps réel dès la soumission du formulaire par le client, sans aucun délai d'attente.

3. Économies Majeures (Coût d'Exploitation Nul)

Pour 200 réclamations/jour par client sur des dizaines de clients, le modèle ML s'exécute sur le serveur web existant sans générer de facturation API externe.

4. Simplicité d'Intégration Web (ZenAssist)

Le modèle est pré-entraîné et sauvegardé sous forme d'un fichier léger de seulement 3.9 Mo (`'best_ml_model.joblib'`). Il s'intègre en 10 lignes de code dans l'API Back-end Python/Node.js de ZenAssist.